# 🌱 文系大学生による『Python再定義辞書』— 機械学習・深層学習 編 —

著： 岡野 菜月 ( 四国大学文学部 / 28卒 )
GitHub： https://github.com/NatsukiOkano

## 📝 資料の概要

＊ 書籍「Python 実践データ分析100本ノック 第3版」( 秀和システム新社刊 ) の学習過程を記録したものです。
＊ 最大の特徴は、「文学部の視点でIT・データ分析を再解釈する」という試みにあります。
＊ 非情報系の学習者が直面する「専門用語の壁」を取り払うため、すべての処理に対し、論理的かつ直感的な「完全独自解説」を記述しています。

## 📚 教材

下山輝昌・松田雄馬・三木孝行 著「Python 実践データ分析100本ノック 第3版」( 秀和システム新社、2025 )

## 🧬 sklearn

### 加工・変換

| コード | 定義 |
|---|---|
| `StandardScaler()` | 補正装置。バラついたデータの単位や型を標準化して均一に整える。※ AIではない。 |
| `sc.fit_transform()` | クラス（StandardScaler）に、読み込ませたデータを一気に補正してもらう。 |
| `モデル.transform` | AIの学習をデータに適用する。 |
| `PCA()` | 主成分分析AI。次元削減を実行する。モジュール（decomposition）に格納される。 |
| `PCA(n_components=)` | 主成分分析AI（PCA）に「最終的に合成して作り出す新しい列の数」を指定する。 |
| `train_test_split()` | 学習用データと評価用データに分割する。<br>※ 過学習状態を避けるため。無指定の場合、学習用データ（75%）、評価用データ（25%）に分割される。 |

### モデル作成・学習

| コード | 定義 |
|---|---|
| `KMeans()` | グループの平均値を探すAI。グループ全体のバラつき（標準偏差）を最小限にする。K = グループ数。 |

| | |
|---|---|
| **KMeans(n_clusters=)** | グループの平均値を探すAI（KMeans）にクラスタ数を指定する。 |
| **LinearRegression()** | 線形回帰AI。バラバラなデータに「直線」を引いてルールを見つけるAI。教師あり学習の「回帰」を担当する。 |
| **DecisionTreeClassifier()** | 決定木AI。分類を担当。カテゴリカル変数（区分）に振り分ける。 |
| **DecisionTreeRegressor()** | 決定木AI。回帰を担当。離散値や連続値（数値）を予測する。 |
| **DecisionTreeClassifier(max_depth=)** | 「決定木の枝分かれを、最大で何段まで許可するか」を決める。 |
| **max_depth=** | 決定木専用の引数。 |
| **max_depth=5** | 質問を5段階まで繰り返す。 |
| **max_depth=None** | 制限なし。データが完全に分かれるまで、質問を繰り返す。※ None： 値が存在しない。 |
| **モデル.fit** | AIの学習を開始する。 |
| **引数「random_state」** | AIのランダム性（気の変わり）を抑える。※ 様々なライブラリで共通して使われる。 |
| **random_state=0** | 毎回、「0」が名前に設定されたデータを出力。 |

## 予測結果の確認・評価

| コード | 定義 |
|---|---|
| **model.predict(df)** | AIで未来の数値を予測する。 |
| **model.predict_proba(df)** | 分類AIが予測した区分が各カテゴリカル変数に該当する確率（0.0〜1.0）を求める。 |
| **model.score(説明変数, 目的変数)** | 「モデル（AI）の予測精度（0〜1）」を測る。 |
| **＊ モデル（AI）の予測精度（0〜1）＊** | 「1」完璧。過学習状態を疑う。<br>「0.7〜0.9」優秀。ビジネス(商売)で自信をもって使えるレベル。<br>「0.5〜0.6」実用圏内。傾向はつかめている。もっとデータを増やせば予測精度が上がるかも。<br>「0.3以下」厳しい。「説明変数が足りない」か、「データのバラつきが大きくて直線で表すには無理がある」<br>「0」使い物にならない。平均値を答えるより外れている。やり直し！ |
| **モデル.labels_** | AIに「学習結果（グループ化した結果）を格納したグループ番号」を自動で入力してもらう。 |
| **model.coef_** | ライブラリ（sklearn）で定義された回帰モデルの係数。データが予測結果に与えている影響力を数値化。 |
| **model.feature_importances_** | ライブラリ（sklearn）で定義された決定木の係数。各説明変数の「予測への寄与度（重要度）」を「0〜1」で表す。 |

### 予測結果の可視化

| コード | 定義 |
|---|---|
| plot_tree(学習済みAIモデル, feature_names=変数名, fontsize=) | 樹形図。 |
| 変数「feature_names」 | 分岐条件に表示させる変数名（列ラベル）。 |
| 変数「fontsize」 | 文字の大きさ。 |

## 🔥 torch

### 環境確認

| コード | 定義 |
|---|---|
| 関数（is_available） | NVIDIA社 / GPU専用内部API（cuda）が利用可能か確認する。True = 利用可能, False = 利用不可 |