🍃 文系大学生による『Python再定義辞書』— 数値計算・データ分析 編 —

著： 岡野 菜月 (四国大学文学部 / 28卒)
GitHub： https://github.com/NatsukiOkano

📝 資料の概要

＊ 書籍「Python 実践データ分析100本ノック 第3版」(秀和システム新社刊) の学習過程を記録したものです。
＊ 最大の特徴は、「文学部の視点でIT・データ分析を再解釈する」という試みにあります。
＊ 非情報系の学習者が直面する「専門用語の壁」を取り払うため、すべての処理に対し、論理的かつ直感的な「完全独自解説」を記述しています。

📚 教材

下山輝昌・松田雄馬・三木孝行 著「Python 実践データ分析100本ノック 第3版」(秀和システム新社、2025)

Python標準

基本関数

コード	定義
`print()`	目に見えるように、外に出して表示する。
`len()`	データの件数を数える。Excelのcount関数と同じ役割。
`list()`	抽出したデータをPython標準の「リスト型」に変換する。
`range()`	指定した回数分、実行を繰り返す。
`abs()`	絶対値（0から離れている数）を求める。
`from ライブラリ import ツール`	インストール済みのライブラリから（`from`）、特定のツールをプログラムに導入（`import`）する。

削除・結合

コード	定義
`del`	データ（オブジェクト）そのものを抹消するためのPython標準の命令。※ 1つしか削除できない。
`df.drop()`	不要なものをまとめて削除する。
`df.extend()`	指定したリストのデータのみ最後に追加する。 例：`[1, 2, 3]`に、`[4, 5]`を追加。`append() [1, 2, 3, [4, 5]]`、`extend() [1, 2, 3, 4, 5]`

制御構文

コード	定義
`if`	もし〜なら
`else`	そうでなければ
`elif`	「`else + if`」あるいは〜なら

if not (変数A in 変数B)	もし、変数Aに変数Bが含まれていなければ
while()	()している間、ずっと繰り返す。
for i in range()	「繰り返し処理」の基本セット。～の間、繰り返す。「for」～の間、繰り返す。「i」今、何回目か数えるための変数。「range」繰り返す回数。
break	実行中の繰り返し処理を強制的に終了させる。
continue	検出せず、次の手順に進む。
「try:」	エラーが発生する可能性があるが、以下のプログラムの実行を試す。
「except Exception as e:」	エラーの原因を変数(e)に格納して、次の手順に進む。
「except:」	エラーが発生した場合、以下のプログラムを実行。
「Exception」	全てのエラーを指す、Pythonプログラム共通のコード。
「as 変数」	今回のプログラムで発生したエラーを変数に格納。
enumerate(デジタル画像，インデックス)	インデックス（0から始まる管理番号）をデジタル画像に授ける。

関数定義

コード	定義
def	「define（定義する）」の略。手順を関数として定義する。
def trans_cost(df_tr, df_tc, ...)	def 手順に名付けた関数名(変数1, 変数2, ...) ※ 関数 = 計算式。変数1, 変数2 = 定義する関数の素材。
return	結果を返して終了する。
return 1	出力失敗。異常あり(1)。エラー。
return 0	出力成功。異常なし(0)。結果を返して終了する。
return 変数	関数の中から結果を反映させた変数を取り出す。 ※ 関数の要素となった変数は、「 return df」で取り出さなければ表示されない。
	※ 関数の中で起きたことは、関数の外からは見えない。

データ構造

コード	定義
リスト[]	[要素，要素，要素，...] ※リスト内の1つ1つのデータを「要素」と呼ぶ。
二次元リスト	表データ。リストを要素に持つリスト。
辞書：変数 = {'文字列':数値，'文字列':数値，.....}	キー（文字列）とそれに対応する数値を結合させて、データを管理するデータ型。
辞書.items()	1要素 = {キー:値} = item
zip(変数1，変数2)	変数1と変数2の同じインデックス（要素の管理番号）でデータを結びつける。Python標準の関数。

演算子・特殊変数

コード	定義

代入演算子「=」	代入。例： x = 100（xに100を代入。）→これ以降、xは100として扱われる。
比較演算子「==」	比較（判定)。例： x == 100（xの中身は100と同じ？）→もしxが100ならTrueになる。
否定演算子「~」	「NOT（〜ではない)」を意味する記号。例： ~flg_is_null（flg_is_nullの反対。）
None	値が存在しない。
a += 1	a = a + 1
round()	数値を四捨五入する。
****変数**	変数に設定した複数の引数を対象の関数に全て代入する。

文字列操作

コード	定義
join()	結合。
f-string（f文字列）	文字と変数を繋ぐ。※ f-string（f文字列）= .format()
例文：「.format()」	{}の担当は{}です'.format(month,name)
例文：「f-string（f文字列)」	f'{month}の担当は{name}です'
.strip()	文字列（str）の両端の空白を削除する。
.lstrip()	文字列（str）の左側の空白を削除する。
.rstrip()	文字列（str）の右側の空白を削除する。
.strip('Node')	両端の文字（Node）を削除する。
.removeprefix('Node')	先頭の文字（Node）を削除する。
.removesuffix('Node')	末尾の文字（Node）を削除する。
.replace(' ', '')	文字列（str）の間の空間を削除する。
\n	改行
\t	インデント
splitlines()	文字列専用。改行（\n）を目印に、文章の1文をリストの要素とする。
split()	文字列専用。空白, タブ（\t）, 特定の文字を目印に、文章の単語をリストの要素とする。
split()[0]	split()で実行されたリストのインデックス（管理番号）0を抽出する。
文字列の改行	シングルコーテーション（'）またはダブルコーテーション（"）を文字の前後に3つずつ付ける。

🐼 Pandas

入出力

コード	定義
pd.read_csv('ファイル名', index_col=)	CSVファイルの読み込み

index_col	どの変数を「行ラベル兼index」として使うかを指定する。※実行すると、元のindex (行番号) は削除される。
df.to_csv('ファイル名', index=)	データをCSV形式で保存する。※ 分析結果をExcelで確認できるようにする。
index=True	行番号もファイルに書き出す（保存する）。
index=False	行番号を捨てて、中身だけ保存する。

データ確認

コード	定義
df.head()	データの最初の5行を表示
df.dtypes	データフレームのクラス（データ型）を確認する。
＊ df.dtypesで確認できるクラス（データ型）＊	int（整数） float（小数） object（pandasが列の種類を表示するときに使う独自の文字列の名称。） ※ str（Python全体での文字列の名称。）str = object datetime（日付・時間）
df.describe()	基礎統計量を表示する。
＊ df.describe()で表示される基礎統計量 ＊	count（データ数） mean（平均値） std（標準偏差） min（最小値） 25%（第1四分位数） 50%（第2四分位数 ※ 中央値） 75%（第3四分位数） max（第4四分位数 ※ 最大値）
df.dtypes	データフレームのクラス（データ型）を確認する。
df.sample()	データをシャッフルして、公平に選び出す。
df.sample(frac=1)	全データ（100%）をシャッフルして、公平に選び出す。※ frac： 割合
pd.unique()	重複を削ぎ落した「純粋な種類の一覧」を1行で表示させる。

結合・変形

コード	定義
pd.concat(df, ignore_index=)	結合。同じ形式（列名）のデータフレーム（表）を、縦（行方向）に結合する。
引数「ignore_index」	0から順番に行番号（index）を新しく振り直す。
ignore_index=True	0から順番に行番号（index）を新しく振り直す。

ignore_index=False	0から順番に行番号（index）を新しく振り直さず、元の行番号(index)を使う。
pd.merge(左の表,右の表, left_on=, right_on=, how=)	結合。正規化されてバラバラになったデータを、分析しやすいように「逆正規化（合体）」させる。
引数「left_on」	左側の表（テーブル）の使用する列名を指定。
引数「right_on」	右側の表（テーブル）の使用する列名を指定。
	※ left_on, right_on はそれぞれの表（テーブル）で使う列名が異なるときに使う。
引数「how」	表（テーブル）の結合方法を指定。
how='left'	左の表を主役にする。右に一致するデータがなくても、左のデータはすべて残す。
how='right'	右の表を主役にする。左に一致するデータがなくても、右のデータはすべて残す。
how='inner'	両方の表にあるデータだけを残す。どちらか片方にしかないデータは消える。
how='outer'	両方の表のデータをすべて残す。一致しない部分は「欠損値（NaN）」で埋める。
df.append()	指定したリストごと最後に追加する。 例：[1, 2, 3]に、[4, 5]を追加。append() [1, 2, 3, [4, 5]]、extend() [1, 2, 3, 4, 5]
df.assign(新しい列ラベル)	データフレームに新しい列を付け加える。※ 行を付け加えることはできない。

欠損値処理

コード	定義
isnull().sum()	欠損値（空白のセル）の合計。
df.isnull().any(axis=)	「欠損値（NaN）セル」があるかどうかチェックする。→True：ある False：ない
isna()	「欠損値（NaN）セル」があるかチェックする。※ isna() = isnull()
any()	どれか、ひとつでも
引数「axis」	処理する向き　axis=0：縦（列）　axis=1：横（行）
df.fillna()	「欠損値（NaN）」を()の値で埋める。 ※ 数値（int, float）だけでなく、文字列（str, object）や日付・時間（datetime）、真偽値（bool値）など、全てのデータ型で使用可能。
df.dropna()	欠損値（NaN）を含むデータをまとめて削除。
	※ 機械学習や深層学習など、ほとんど全てのAIは、欠損値があると対応できない。

抽出・選択

コード	定義
df.loc[行ラベル,列ラベル]	ラベルで指定。ラベルを使って条件に合うデータを探す。
df.iloc[行番号,列番号]	整数で指定。整数を使って条件に合うデータを探す。
df.select_dtypes(include='')	特定のデータ型の列だけを選んで取り出す。
df.select_dtypes(include='number')	「数字（number）」を「含める（include）」列だけを選んで取り出す。
df.where(条件, 書き換え値)	条件に合うデータはそのまま残し、合わないデータは書き換える。

df.where(df['列ラベル'] < 4, 1)	列ラベルが「4未満」ならそのまま。そうでなければ、「1」に書き換える。
df.drop_duplicates(subset='列ラベル')	重複したデータを削除する。※ subset：実行する範囲を指定。

集計・並べ替え

コード	定義
df.groupby('列ラベル', as_index=)	データを同じ仲間ごとにグループ分けする。
引数「as_index」	グループ化した項目を、新しい表の「見出し（インデックス）」にするか、「普通のデータ（列）」のままにするか決める。
as_index = True	グループ名が、新しい表の「見出し（インデックス）」に。
as_index = False	グループ名がそのまま「普通のデータ（列）」として残る。
df.sort_values(by=[' '],ascending=)	表のデータを、特定の項目（列）を基準に並び替える。
引数「by」	「どの列を基準にするか」を指定。
引数「ascending」	降順（False,0）か昇順（True,1）どっちで並べ替えるか設定する。
df.agg()	複数の計算（合計、平均、最大値など）をまとめて集計する。
df.sort_values('変数名(列ラベル)',ascending=)	数値の並べ替えを実行する。
引数「ascending」	降順（False,0）か昇順（True,1）どっちで並べ替えるか設定する。
pd.pivot_table(表の名前,index=,columns=,values=,aggfunc=,fill_value=)	クロス集計表（Excelの表）を作る。
引数「index=」	行ラベル（縦軸）
引数「columns=」	列ラベル（横軸）
引数「values=」	値（計算対象）
引数「aggfunc=」	値の集計設定（基礎統計量）※ よく使う基礎統計量： sum（合計）,count（個数）,mean（平均値）,std（標準偏差）,median（中央値）
引数「fill_value」	空欄を埋めるための値の設定。
fill_value=0	空欄のセルは「NaN」ではなく「0」を入れる。

加工・変換

コード	定義
to	～へ変換する。
df.reset_index(drop=)	バラバラになったり、行ラベル（index）になってしまった行番号を、上から「0」から順に振り直す。
df.reset_index(drop=True)	今の行ラベル（index）を削除して、行番号を新しく振り直す。
df.reset_index(drop=False)	今の行ラベル（index）を残しつつ、行番号を新しく振り直す。
df.rename(columns={'変更前':'変更後'}, inplace=)	列ラベル（columns）や行ラベル（index）を書き換える。
引数「inplace」	「『元のデータ』そのものに修正を加える」か、「『コピーした新しいデータ』に修正を加えてユーザーに渡す」か決める。
inplace = True	『元のデータ』そのものに修正を加える。※ユーザーに渡さない。
inplace = False	『コピーした新しいデータ』に修正を加えてユーザーに渡す。

df.astype('クラス')	クラス（データ型）を強制的に変更する。
＊ astype()でよく使うクラス ＊	int（整数） float（小数） object（pandasが列の種類を表示するときに使う独自の文字列の名称。） ※ str（Python全体での文字列の名称。）str＝object
pd.get_dummies(df)	ダミー変数を作成する。
df.copy()	複製。コピーして新しいデータフレーム（表）を作る。
df.assign(cluster = clusters.labels_)	AIに「cluster」という名前の新しい列に「学習結果（グループ化した結果）を格納したグループ番号」を自動で入力してもらう。

文字列操作

コード	定義
df.str.upper()	アルファベットを全て大文字に変換する。
df.str.isdigit()	「文字列（str）の中身が、0〜9の数字だけで構成されているか」をチェックする。
df.str.replace('古い文字', '新しい文字')	古い文字を探して、新しい文字に入れ替える。
regex	引数。メタ文字（規則性のある記号）の設定。
regex=True	メタ文字として機能させる。
regex=False	メタ文字として機能させない。

日付操作

コード	定義
pd.to_datetime(df['列ラベル'], format='')	AIに日付（文字）の読み方を「 % 」で学習させる。
format=	「’%Y’」西暦（4桁）例：2025 「'%y'」西暦（2桁）例：25 「'%m'」月（2桁）例：02 「'%d'」日（2桁）例：03 「'%H'」時（2桁）例：15 「'%M'」分（2桁）例：31
pd.to_timedelta('')	文字（object)」として読み込まれた期間を、計算・加工可能な『特定の期間（timedelta)』に作り変える命令。
dt.strftime(’’)	時間を、形式を整えた文字にする。「dt」datetimeの略。※ strftime ＝ string（文字）format（形式を整える）time（時間）の略。 「’%Y’」西暦（4桁）例：2025 「'%y'」西暦（2桁）例：25 「'%m'」月（2桁）例：02 「'%d'」日（2桁）例：03

	「'%H'」時（2桁）例：15 「'%M'」分（2桁）例：31
dt.weekday	指定した日付が「何曜日か」を数字で教えてくれる。曜日は「0（月）～ 6（日）の数字」で管理される。

データ構造

コード	定義
pd.Series()	一次元リスト（列）。全ての要素にインデックス（管理番号）が付いている。例： 'A':[1, 2, 3], 'B':[4, 5, 6]
pd.DataFrame()	二次元リスト。Seriesの集合体。
pd.DataFrame(データ,行ラベル,列ラベル)	データフレーム（表）を作成する。

📐 numpy

配列作成

コード	定義
np.zeros()	要素（データ）が全て「0」の表またはリストを新しく作成する。
np.ones()	「1」を要素に持つSeries（一次元リスト）を作成する。
np.ones(5)	[1, 1, 1, 1, 1]
np.arange(開始, 終了, 間隔)	開始から終了までの数値を一定の間隔で自動生成する。
np.linspace(開始値, 終了値, 要素値)	開始値から終了値までを要素数で等間隔に分割した、数値のNumPy配列（ndarray）を作成する。
np.linspace(0, 100, 5)	[0, 25, 50, 75, 100], np.linspace(0, 100, 2) = [0, 100]

統計・計算

コード	定義
np.min()	Python標準のリスト, PandasのSeries / DataFrame, NumPy配列 (ndarray) から最小値を抽出する。
np.max()	Python標準のリスト, PandasのSeries / DataFrame, NumPy配列 (ndarray) から最大値を抽出する。
np.size()	Python標準のリスト, PandasのSeries / DataFrame, NumPy配列 (ndarray) に格納される要素数を数える。
np.convolve()	畳み込み積分で移動平均を求める。※ インデックス（管理番号）が近い要素をグループ化して、その中の平均値を持った要素をグループの代表値とする。
np.dot()	内積（スカラー積）を計算する。2つの変数に対応するベクトルの特徴量の積の和を求める。

乱数

コード	定義
np.random.rand()	「0以上1未満」の乱数を設定。
np.random.seed(1)	乱数の発生パターン（型）を「1」が名前の設定に固定。

数値定義

コード	定義
`np.nan`	欠損値
`inf`	上限なし（無限大）

線形代数

コード	定義
`np.linalg.norm()`	ライブラリ（numpy）に格納されるモジュール（linalg）から関数（norm）を自分のプログラムに導入する。
モジュール（linalg）	線形代数（ベクトル空間を研究する数学理論）のプログラムを格納したファイル。
関数（norm）	特定のベクトルからスカラー計算。特定（1つ）の変数に対応する特徴量のスカラーを計算する。

🔢 math

三角関数

コード	定義
`math.sin(角度)`	正弦。角度から、高さと斜辺の比率を求める。sin = 高さ÷斜辺
`math.cos(角度)`	余弦。角度から、底辺と斜辺の比率を求める。cos = 底辺÷斜辺
`math.tan(角度)`	正接。角度から、高さと底辺の比率を求める。tan = 高さ÷底辺

逆三角関数

コード	定義
`math.asin(高さ / 斜辺)`	逆正弦。高さと斜辺の比率から、角度を求める。
`math.acos(底辺 / 斜辺)`	逆余弦。底辺と斜辺の比率から、角度を求める。
`math.atan(高さ / 底辺)`	逆正接。高さと底辺の比率から、角度を求める。

数学定義

コード	定義
`math.pi`	円周率。少数第15位まで出力。（3.141592653589793）

∞ itertools

全組み合わせ作成

コード	定義
`product()`	データを結合してクラス（LpVariable）に入れる素材を自動で作成する。