🍂 文系大学生による『Python再定義辞書』— 自然言語処理（NLP）編 —

著： 岡野 菜月 (四国大学文学部 / 28卒)
GitHub： https://github.com/NatsukiOkano

📝 資料の概要

＊ 書籍「Python 実践データ分析100本ノック 第3版」(秀和システム新社刊) の学習過程を記録したものです。
＊ 最大の特徴は、「文学部の視点でIT・データ分析を再解釈する」という試みにあります。
＊ 非情報系の学習者が直面する「専門用語の壁」を取り払うため、すべての処理に対し、論理的かつ直感的な「完全独自解説」を記述しています。

📚 教材

下山輝昌・松田雄馬・三木孝行 著「Python 実践データ分析100本ノック 第3版」(秀和システム新社、2025)

🌿 MeCab

形態素解析

コード	定義
`Tagger()`	品詞データを読み込み、形態素解析できる状態で待機する。
`tagger.parse()`	形態素解析（Tagger）を実行する。

🎯 re

正規表現

コード	定義

re.search(正規表現，対象の文字列，追加設定※ 任意)	対象の文字列から、正規表現を検出する。
re.search()の変数.group()	文字列からre.search()で設定した正規表現を含む文字列を抽出する。
re.search()の変数.group(0)	設定した全ての正規表現を含む文字列を抽出する。
re.search()の変数.group(1)	1番目に設定した正規表現を含む文字列を抽出する。
re.search()の変数.group(152)	152番目に設定した正規表現を含む文字列を抽出する。
re.DOTALL	改行をエラーではなく、文字として認識する。
＊ 基礎的なメタ文字 ＊	「 \ 」エスケープ文字。「\」の後に続く文字の本来の意味を無効化して、ただの文字として機能させる。 「 \(, \) 」グループ化の意味を持つ「 () 」を、ただの文字として機能させる。 ※ エスケープ文字は、Windowsでは「半角円マーク」。Mac / Linuxでは「 \ 」として表示される。 「 () 」グループ化。 「 . 」任意の1文字。（改行を除く）例： a.c = 'abc', 'axc' 「 * 」直前の文字が0回以上繰り返す。例： a* = '', 'a', 'aaa' 「 + 」直前の文字が1回以上繰り返す。例： a+ = 'a', 'aaa' 「 ? 」直前の文字が0回または1回。例： a? = '', 'a' 「 +? 」最短一致。「+」の検出範囲を制限する。